重要

关键技术（**量化**、剪枝概念/分类/技术/范式、蒸馏四个概念、温度参数

主流框架了解

边缘智能

边缘智能：指将AI模型与算法部署于**靠近数据源**的 **IoT 终端、边缘网关等计算节点**，利用**本地算力**开展数据分析、模型推理、场景感知与智能决策的技术与应用模式。

1. **应用**：桌面机器人、边缘智能网关
2. **使用流程**：
   - **训练**：**从数据中学习参数**：前向计算→计算损失→反向传播更新参数；用验证集评估
   - **压缩优化**：降低存储和计算开销，**适配边缘设备的资源限制**；转换格式并复核性能
   - **部署**：**在目标硬件上运行应用**
3. **常见DNN结构**：
   - CNN卷积神经网络：提取**局部空间**特征（图像分类、目标检测）
   - RNN循环神经网络：按**时间**步传递状态（时序信号、语音）
   - Transformer：通过注意力关联不同位置（语言、视觉任务）

关键特性

1. **模型规模**：模型包含的`参数总量`（权重、偏置等）
   a. **模型参数：**模型内部用于确定输入与输出之间关系的数值，其取值通常通过训练从数据中学习得到。
      i. `参数越多，通常`**`学习容量`**`越大`，但**不代表准确率一定更高。**
   b. **`参数数据类型`是影响模型权重存储占用的重要因素**（权重=参数量 × 每参数字节数）
2. **运行时内存**：M_peak ≈ M_W + M_A + M_KV + M_R（W 权重；A 中间张量；KV 自回归缓存；R 额外开销）
3. **`精度`**
   a. **准确率**：预测正确的样本占总样本的比例**= (TP+TN) / (TP+FP+TN+FN)**
   b. **精确率**：预测为正例中真正为正的比例，预测可信度**= TP / (TP+FP)**
   c. **召回率**：实际正类中被正确预测的比例**= TP / (TP+FN)**
   d. **F1 分数**：精确率与召回率的调和平均**= 2•P•R / (P+R)**
4. **延迟/吞吐量**：相互制约
   a. 延迟 ms：完成一次请求花费的时间
   b. 吞吐量 样本/秒：单位时间内处理的数据总量

> FLOPs：运算次数，衡量模型计算量。FLOPS：每秒运算次数，衡量硬件算力。MACs：乘加次数；通常按1 MAC≈2 FLOPs计

5. **能耗**：能耗 = 平均功耗 × 推理时延
   a. 优化策略：模型量化、算子融合
6. **支持硬件**：CPU、GPU（卷积、矩阵等并行任务）、NPU（神经网络计算）

三者互斥：提升精度牺牲速度/资源；压缩资源易致精度崩塌

关键技术-模型压缩

量化

降低参数数值精度（特定映射函数：高精度浮点FP32->低精度整数INT8），以减小模型、降低访存和计算开销

1. **量化原理**：两个关键参数，线性量化的求解方法 MinMax：$S = \frac{x_{\max} - x_{\min}}{q_{\max} - q_{\min}}, Z \approx \text{round}\left(q_{\min} - \frac{x_{\min}}{S}\right)$
   a. **Scale（S）**：缩放因子，表示量化步长。
   b. **Zero Point（Z）**：零点，使浮点数0能够准确映射到整数。
2. **量化分类**
   - **线性/非线性量化**：浮点值与量化值的映射关系是否均匀（非线性难）
   - **对称/非对称量化**：线性量化、是否使用浮动"零点"参数（对称：零点为0）
3. **量化方式**
   - **按量化时机**：训练后量化PTQ、量化感知训练QAT
     - QAT：训练或微调时加入**伪量化**，模拟量化误差，让模型适应低精度。通常**精度保持较好**，但需要修改训练代码，训练成本较高。
   - **按激活值处理方式**：
     - **动态量化**：仅权重离线量化，激活值在推理时量化（实时计算S和Z）
       - **实施成本低、无需校准数据**，但有运行时量化开销。
     - **静态量化**：权重与激活值均离线量化。用代表性"校准数据集"推理几次，预计算出固定的S和Z。
       - **推理速度快，但需要校准集进行校准**

特性维度	动态量化	静态量化	QAT
实施复杂度	最低，即插即用	中等，需校准步骤	最高，需修改训练流程
校准数据	无需	需代表性校准集	无需（训练中感知）
推理速度	一般	最快	最快
精度	较高	较高	最高
适用场景	Transformer/RNN等	CNN 等固定结构	精度要求极高场景

追求快速部署用动态量化，追求推理速度用静态量化，追求极致精度用QAT。

4. **量化方法失效**
   a. 当模型规模超过60亿，量化方法性能急剧下降
   b. **LLM**异常值数值极大（**离群值**），经典方法：LLM.int8()，常规值普通量化，异常值保留高精度

思考题1

1. **动态量化 vs. 静态量化：如果追求极致的推理速度，应该选哪种？为什么？**
   通常选**静态量化**。通过离线校准提前确定激活值的量化参数，减少推理时统计范围、量化和反量化的开销，更容易实现高效INT8推理。
2. 💥**在确定量化范围（截断阈值）时，直接取最大值（MinMax）有什么坏处？**
   容易受离群值影响。极端值拉大量化范围，使量化步长变大，导致多数正常值的表示变粗，量化误差增大、准确率下降

3. 🌟**为什么大语言模型（LLM）比传统的CNN模型更难量化？**
   LLM中存在**数值很大、但对预测十分重要的离群特征**。保留它们会拉大量化范围，降低普通值的表示精度；直接截断又会损失关键信息，因此更难兼顾压缩与准确率。

剪枝

系统性地移除神经网络中冗余或不重要的组成部分(权重、神经元、通道、网络层)（**改变模型架构、减少参数数量**）,降低模型复杂度。（减小尺寸、加速推理、降低能耗）

1. **分类**：
   a. **非结构化**：移除单个独立的权重或神经元连接；
      i. **高稀疏度、精细，但是硬件加速难、实现复杂**
   b. **结构化**：移除整个结构化单元
      i. 卷积层的整个通道/滤波器、全连接层的神经元、Transformer模型的注意力头、整个网络层
      ii. **硬件友好、简化部署但精度挑战大、剪枝粒度粗糙**

特性	非结构化剪枝	结构化剪枝
移除单元	单个权重	整个滤波器、神经元、层等
稀疏模式	不规则、细粒度稀疏	规则，对齐硬件计算单元
主要优势	灵活性高，精度保持度好	可在通用硬件上实现显著的实际推理加速
主要挑战	难以在通用硬件上获得实际加速，需特殊库/硬件支持	灵活性较低，更容易造成精度下降
实际延迟增益	通常极小或无，依赖特定软硬件	显著，兼容标准密集计算库

L1 范数策略和**随机策略**?

2. **剪枝方法**
   a. 基于幅度：权重绝对值；**L1 范数(绝对值之和)或 L2 范数(平方和的平方根)**
   b. 基于梯度：估计删除后对损失的影响

思考题2

1. **我们通常使用L1范数（权重的绝对值大小）作为剪枝标准，认为绝对值越小的权重越不重要。是否存在"权重绝对值很小，但其实对模型非常重要"的情况？**
   存在。权重的重要性还取决于输入大小、梯度及其在网络中的作用。例如，权重虽小，但输入很大，其输出贡献仍可能很大。因此，**不能仅凭绝对值判断重要性**，还可结合梯度或剪除后损失的变化。
2. **为什么剪枝通常是"训练→剪枝→微调"的迭代过程，而不是直接从头训练小模型？**
   大模型通常更容易学习到丰富的特征；**剪枝保留已学到的重要结构，微调补偿删除参数造成的精度损失**。逐步迭代可以避免一次剪枝过多导致性能骤降。直接训练小模型也可行，但不一定达到同样效果。

蒸馏

将结构复杂、性能卓越的教师模型学到的**深层知识与泛化能力**,迁移到**结构精简、参数更少**的学生模型。

1. **核心概念**：
   a. **教师模型**：输出知识；

b. **学生模型**：接收知识，在保持低计算成本和推理速度的同时，尽可能地模仿和复现教师模型的性能表现

c. **硬标签**：真实数据的标注，**独热编码**；离散性、明确性

d. **软标签**：教师模型的输出**概率**分布

> **独热编码（One-Hot Encoding）**：用一个向量表示类别，**对应类别的位置为1，其余位置为0**
>
> **温度参数T**：高T忽略细节，低T放大噪声
>
> - **T＞1**：分布更**平滑**，突出低概率类别的贡献
> - **T＝1**：标准Softmax输出
> - **0＜T＜1**：接近独热编码

2. **蒸馏分类**：按照知识形式

a. **基于响应**：学习教师的**最终预测结果**。

b. **基于特征**：学习教师的**中间层特征**。

c. **基于关系**：学习**样本之间或特征层之间的结构化关系**。

3. **蒸馏算法**：Hinton知识蒸馏（基于响应）：软标签+硬标签混合训练

a. **组合损失**函数：**为什么需要组合损失？**

i. **软目标**：提供类别关系和泛化信息，帮助学生学习教师的结构化知识

ii. **硬目标**：提供真实标签作为**"锚点"**，纠正教师可能存在的偏差和噪声，防止学生偏离真实分布。

> **思考题3**
>
> 1. **在计算蒸馏的总损失时，为什么包含两部分（软损失＋硬损失）？只用软标签不行吗？**
> 软损失传递教师的类别关系等知识，硬损失利用真实标签纠正偏差。只用软标签也能训练，但可能继承教师的错误；结合硬标签通常更可靠。
> 2. **教师模型一定越强越好吗？让超级复杂的模型（如GPT-4级别）教非常简单的模型（如几层的小网络），效果一定好吗？**
> 不一定。学生容量有限，师生差距过大时，学生可能难以学会教师的复杂知识。应选择能力匹配的教师，或通过**中间教师逐级蒸馏**。

云边协同

将边缘侧的本地计算能力与云端的远程计算能力结合

协同模式分类：

1. **智能路由**：以推理请求为单位，选择由边缘侧或云端的不同模型处理
2. **分割计算**：以模型内部的计算为单位，将**同一个**模型的不同部分安排在边缘侧和云端执行

a. 设计思想：在计算与通信之间寻求最优平衡

b. 边缘负责低延迟的前端处理，云端负责高算力的后续推理

主流框架

通用端侧选TFLite，跨平台选ONNX Runtime，本地LLM选llama.cpp

- **TensorFlow Lite**：面向**移动端和嵌入式设备**
- **ONNX Runtime**：面向**跨框架、跨硬件部署**
- **llama.cpp**：面向**本地大语言模型推理**